

LAPORAN INDIVIDU MACHINE LEARNING

**KLASIFIKASI TINGKAT KEMATANGAN PISANG MENGGUNAKAN SUPPORT
VECTOR MACHINE BERDASARKAN EKSTRAKSI FITUR RUANG WARNA HSV**

Disusun oleh:

Abdurrahman Gilang Harjuna 2310817110004

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Pisang merupakan komoditas buah klimaterik dengan nilai ekonomi tinggi yang memiliki karakteristik proses pematangan yang sangat cepat setelah dipetik. Hal ini menimbulkan tantangan besar dalam industri karena identifikasi tingkat kematangan yang tidak tepat dapat memicu kerugian pascapanen (post-harvest loss) yang signifikan dan menghambat kelancaran perdagangan buah secara internasional (Thayumanavan Shuprajhaa, 2023). Di banyak industri, proses penyortiran tingkat kematangan masih mengandalkan inspeksi visual oleh manusia. Namun, metode manual ini dinilai sangat lambat, menguras tenaga fisik dan fokus (labor-intensive), serta sering kali bersifat merusak atau destruktif terhadap sampel buah (Kristian M. S. Callaghan, 2025). Selain itu, pengamatan manusia memiliki keterbatasan berupa sifat subjektivitas yang tinggi sehingga hasil penilaian seringkali tidak konsisten akibat faktor kelelahan visual maupun perbedaan persepsi antar pekerja (Preety Baglat, 2023).

Karena kendala tersebut, industri memerlukan sistem identifikasi otomatis yang bersifat non-destruktif untuk menjaga kualitas fisik buah selama proses pengujian. Para peneliti sudah membuktikan bahwa analisis warna pada kulit buah merupakan internal buah tanpa harus dirusak (Lukai Ma, 2022). Penggunaan visi komputer melalui citra digital menawarkan solusi penilaian kualitas yang lebih objektif, cepat, dan terstandarisasi (Vassilia J. Sinanoglou, 2023).

Dalam penelitian ini menggunakan ekstraksi fitur ruang warna HSV (Hue, Saturation, Value) karena kemampuannya memisahkan informasi warna murni dari gangguan intensitas cahaya atau bayangan, yang merupakan parameter krusial dalam klasifikasi buah (Preety Baglat, 2023). Pendekatan algoritma Support Vector Machine (SVM) dipilih karena kemampuannya untuk menghasilkan sistem klasifikasi digital yang berbiaya rendah (low-cost) namun tetap memiliki akurasi yang tinggi serta akses data yang instan (Kristian M. S. Callaghan, 2025). Dengan integrasi ini diharapkan bisa berjalan lebih efektif, efisien, dan akurat dalam proses penyortiran pisang di industri.

1.2 Rumusan Masalah

1. Bagaimana efektivitas ekstraksi fitur ruang warna HSV dalam mengklasifikasikan tingkat kematangan pisang secara non-destruktif?
2. Bagaimana pengaruh penggunaan StandardScaler terhadap tingkat akurasi dan kestabilan model SVM?
3. Manakah kombinasi parameter SVM yang paling optimal dalam membedakan kelas Mentah, Setengah Matang, dan Matang?

1.3 Tujuan Penelitian

1. Membangun model klasifikasi tingkat kematangan pisang berbasis Support Vector Machine (SVM) yang akurat
2. Mengevaluasi performa ekstraksi fitur HSV Histogram dan proses standarisasi data dalam mengenali identitas visual setiap fase kematangan
3. Mendapatkan parameter terbaik (kernel dan nilai C) yang mampu memberikan akurasi maksimal untuk kebutuhan implementasi industry

BAB 2

TINJAUAN PUSTAKA

2.1 Kajian Pustaka

No	Judul Artikel	Nama Penulis	Nama Jurnal	Tahun Terbit	DOI/Link Jurnal	Alasan Memilih
1	Prediction of banana maturity based on the sweetness and color value of different segments during rippering	Lukai Ma et al	Current Research in Food Science	2022	https://doi.org/10.1016/j.crfs.2022.08.024	Membahas ekstraksi nilai warna kulit merupakan metode non-destruktif yang akurat untuk memprediksi tingkat kematangan buah
2	Quality Assesment of Banana Ripening Stages by Combining Analytical Methods and Image Analysis	Vassilia J. Sinanoglu et al	Applied Science	2023	https://doi.org/10.3390/app13063533	Menunjukkan penggunaan Image Analysis (analisis gambar/piksel) untuk mengekstrak parameter warna untuk menghilangkan subjektifitas manusia dalam penilaian kualitas
3	Deep Learning based intelligent identification system for ripening stages of banana	Thayumana van Shuprajhaa et al	Postharvest Biology and Technology	2023	https://doi.org/10.1016/j.postharvbio.2023.112410	Menunjukkan urgensi penanganan masalah post-harvest loss dan memvalidasi posisi algoritma tradisional seperti SVM sebagai baseline klasifikasi yang tangguh

4	Low-Cost, Multisensor Nondestructive Banana Ripeness Estimation Using Machine Learning	Kristian M. S. Callaghan and Uriel Martinez-Hernandez	IEEE Sensors Journal	2025	10.1109/JSEN.2025.3528250	Membuktikan efisiensi algoritma klasik (SVM) dalam menghasilkan klasifikasi dengan akurasi tinggi (>96%) untuk kebutuhan industri berbiaya rendah (Low-Cost)
5	Non-Destructive Banana Ripeness Detection Using Shallow and Deep Learning: A Systematic Review	Preety Baglat et al	Sensors	2023	https://doi.org/10.3390/s23020738	Mengenai ulasan sistematis yang menegaskan bahwa Shallow Learning (seperti SVM) yang dipadukan dengan ruang warna murni adalah metode paling efektif dalam klasifikasi buah cerdas

Knowledge-Based Systems (Jurnal 1 & 5):

2.2 Dasar Teori

2.2.1 Ekstraksi Fitur Visi Komputer dan Ruang Warna HSV

Pengolahan citra digital (Image Analysis) merupakan tahap krusial dalam sistem klasifikasi non-destruktif. Dibandingkan dengan observasi manusia yang subjektif, visi komputer mengekstrak nilai piksel secara objektif (Vassilia J. Sinanoglou, 2023). Dalam penelitian ini menggunakan ruang warna HSV (Hue, Saturation, Value). Berbeda dengan format RGB standar, HSV memisahkan informasi warna murni (Hue) dari intensitas pencahayaan (Value). Dari penelitian (Preety Baglat,

2023) menurutnya representasi warna murni ini adalah fitur paling krusial untuk menahan bias bayangan dan atau pencahayaan ruangan pabrik, sehingga computer dapat mengidentifikasi perubahan fisik kulit pisang secara presisi seperti dibuktikan keakuratannya oleh (Lukai Ma, 2022).

2.2.2 Algoritma Support Vector Machine

Support Vector Machine (SVM) adalah algoritma Machine Learning yang bertugas memisahkan kelompok kelas data dengan mencari bidang pemisah (Hyperline) paling optimal di dalam ruang dimensi fitur (Kristian M. S. Callaghan, 2025). SVM merupakan algoritma klasifikasi yang sangat efisien dalam memproses dataset citra berukuran menengah jika dibandingkan dengan Deep Learning yang membutuhkan komputasi massif (Thayumanavan Shuprajhaa, 2023). SVM bekerja hanya memfokuskan perhitungan pada titik-titik data terluar yang paling dekat dengan batas kelas lain, yang disebut sebagai Support Vectors. Pendekatan ini membuat SVM menjadi algoritma komputasi berbiaya rendah (low-cost) namun mampu menghasilkan tingkat akurasi yang sangat tinggi, bahkan melebihi 96% (Kristian M. S. Callaghan, 2025).

BAB 3

METODOLOGI

3.1 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini terdiri dari 120 gambar dan 40 gambar per classnya lalu di preprocessing dan augmentasi sehingga menghasilkan 360 gambar citra pisang yang dibagi secara seimbang 120 dataset per kelas dalam tiga kategori kematangan yaitu Mentah, Setengah Matang, dan Matang. Penerapan Teknik augmentasi data pada dataset berukuran kecil hingga menengah sangat berguna untuk membantu model klasifikasi yang lebih akurat dan Tangguh terhadap variasi data (Preety Baglat, 2023).

3.2 Tahap Penelitian

3.2.1 Preprocessing

Pada tahapan awal mengubah dataset asli sebanyak 120 gambar, diseragamkan ukurannya menjadi 224x224 piksel dan dikonversi ke format RGB. Lalu dilakukan augmentasi dimana untuk setiap satu gambar asli akan menghasilkan 2 variasi baru dengan menerapkan rotasi acak maksimal 20 derajat dan pembalikan horizontal. Seluruh hasilnya diarsipkan kembali menjadi satu file direktori prapemrosesan yang siap diekstrak pada tahap training nanti.

3.2.2 Feature Ekstaction HSV

Dataset hasil prepemrosesan dibaca kembali untuk proses ekstraksi informasi visual. Setiap citra gambar dikonversi kedalam ruang warna HSV (Hue, Saturation, Value). Pendekatan Image Analysis ini digunakan untuk mengisolasi informasi nilai warna murni untuk meminimalkan bias akibat intensitas Cahaya atau bayangan. Distribusi warna citra diekstrak menggunakan metode Histogram 3D dengan alokasi 8x8x8 bins. Nilai histogram tersebut dinormalisasikan dan diratakan sehingga menghasilkan sebuah vector fitur 1 dimensi yang berisi 512 nilai numerik (array). Vector 512 dimensi inilah yang merepresentasikan fitur murni dari setiap citra.

3.2.3 Data Splitting

Data dipisahkan menggunakan metode Train Test Split dengan rasio 80:20. Pengacakan data dikunci dengan random state=42 dan di proporsikan sesuai dengan jumlah kelas aslinya. Sebanyak 80% datanya dialokasikan sebagai data latih untuk membentuk batas keputusan algoritma, dan 20% diisolasi sebagai data uji untuk mengevaluasi akurasi prediksi.

3.2.4 Standarisasi Fitur (Feature Scaling)

Fitur histogram berdimensi 512 tersebut distandarisasi menggunakan fungsi StandardScaler. Metode ini secara seragam mengubah skala numerik seluruh

dimensi fitur agar memiliki rata rata 0 dan standar deviasinya 1. Normalisasssi ini penting sebelum data diproses oleh agoritma Shallow Learning (SVM) untuk menghindari bias bobot akibat rentang angka fitur yang terlalu bervariasi sehingga perhitungan jarak margin dapat berlangsung secara proporsional.

3.2.5 Pelatihan dan Evaluasi Model

Data latih yang sudah di standarisasi kemudian dipelajari menggunakan algoritma SVM, lalu eksplorasi melalui optimasi Hyperparameter yang memegang peran penting untuk mencapai tingkat akurasi klasifikasi yang tinggi pada kematangan buah pisang. Pelatihan dilakukan secara iterative (looping) untuk menguji berbagai kombinasi hyperparameter dalam skenario percobaan . model dengan akurasi pengujian tertinggi akan disimpan secara otomatis sebagai model terbaik kemudian diukur efektifitas tebakannya melalui Matrik Evaluasi (Classification Report dan Confusion Matrix).

3.3 Skenario Percobaan


Untuk menemukan hyperplane yang paling ideal, penelitian ini menggunakan parameter Kernel dan Parameter C.

```
Percobaan 1 (Linear, C=1.0) | Akurasi: 95.83%
Percobaan 2 (RBF, C=1.0) | Akurasi: 93.06%
Percobaan 3 (RBF, C=10.0) | Akurasi: 91.67%
```

3.4 Analisis Hasil dan Pembahasan

Berdasarkan hasil eksperimen tiga skenario tadi, percobaan 1 Kernel Linear C=1.0 menjadi model terbaik dengan mendapatkan akurasi mencapai 95,83%. Percobaan 2 Kernel RBF C=1.0 mendapatkan akurasi mencapai 93,06%. Percobaan 3 Kernel RBF C=10.0 mendapatkan akurasi mencapai 91,67%. Hasil dari parameter Kernel Linear C=1.0 membuktikan bahwa 512 fitur dimensi tersebut yang diekstrak dari histogram HSV dapat dipisahkan menggunakan batas lurus/hyperplane tanpa memerlukan tranformasi matematis tingkat tinggi. Ini juga membuktikan algoritma klasik SVM ini bisa diandalkan untuk mendapatkan akurasi tinggi tapi tetap low-cost.

Hasil Confusion Matriks



Laporan Matrik Evaluasi Percobaan Terbaik Kernel Linear C=10

Laporan Metrik Evaluasi:

	precision	recall	f1-score	support
Mentah	1.00	0.88	0.93	24
Setengah Matang	0.89	1.00	0.94	24
Matang	1.00	1.00	1.00	24
accuracy			0.96	72
macro avg	0.96	0.96	0.96	72
weighted avg	0.96	0.96	0.96	72